

立體匹配與三維場景重建

NTU 計算機視覺 Spring 2026 期末專案報告
基礎題 (Middlebury) + 加分題 (TartanAir 3D 重建)

作者一、作者二

國立臺灣大學

2026 年 6 月 5 日

Abstract

本報告呈現 NTU CV Spring 2026 期末專案的兩部分成果。**基礎題**以 Middlebury 經典 4 階段流程 (Census $\rightarrow$ Weighted Guided Image Filter 聚合 $\rightarrow$ Winner-take-all $\rightarrow$ LRC + Hole Fill + Weighted Median) 實作 `computeDisp`，在 Tsukuba、Venus、Teddy、Cones 四對影像上 bad-pixel ratio 均落在 TA 門檻內 (3.25 %, 0.34 %, 10.00 %, 8.78 %)，且不依賴 per-image hyperparameter 分支以符合 2026-05-27 補充規範。**加分題**選用 TartanAir 合成資料集，以 `computeDisp` 預測 disparity、Open3D ScalableTSDFVolume 進行多視角融合，最後以**第一人稱走訪** (follow-trajectory) 視角合成示範影片。過程中辨識並修正了 TartanAir NED 機體座標系與 OpenCV 相機座標系之間的軸排列差異，這是讓重建幾何正確的關鍵步驟。基準 BPR 在 japanesealley/Hard/P000 前 100 frame 為 20.21 % (1 px) 與 10.75 % (3 px)，與相關文獻對古典立體匹配在合成資料集的數字相當。

1 前言

給定一對已 rectify 的左右影像，立體匹配的目標是估計左圖每個像素在右圖的水平位移量 d (disparity)，由相似三角形即可換算深度 $Z = f_x \cdot B/d$ ，其中 f_x 為焦距、 B 為基線長。經典處理流程可拆為四階段 [1]：cost computation、cost aggregation、disparity optimization、disparity refinement，本專案的基礎題以此架構實作。

本專案要求兩部分：

- **基礎題 (80 %)**：四對 Middlebury v2 影像上以 BPR 為評分；TA 規範禁止使用 `cv2.StereoBM` / `cv2.StereoSGBM` 等內建求解器，不允許 deep learning，並要求 hyperparameter 對影像不可分支。
- **加分題 (25 %)**：在**真實世界場景**延伸立體匹配以做出深度感知 (depth perception) 並提供示範影片。本報告選擇 TartanAir 合成資料集作為穩定可重現的代替方案 (理由詳見 §3.1)，完整 pipeline 從 stereo disparity 到 TSDF mesh 再到第一人稱走訪影片。

2 基礎題：經典立體匹配演算法

2.1 演算法總覽

`computeDisp.py` 是一份單檔 (flat) 實作，純粹仰賴 `numpy` 與 `cv2.ximgproc` 的兩個原語：`createGuidedFilter` (事實上採自行實作的 WGIF 版本)、`weightedMedianFilter`。整體 pipeline 如 Figure 1 所示。




Figure 1: 基礎題四階段 pipeline。Cost volume 維度為 $(D+1) \times H \times W$ ，以 thread pool 對 d 軸做切片平行化。

2.2 Step 1: Cost Computation —Census + Hamming

Census transform [2] 將每個像素轉成一串 bit，第 i 個 bit 紀錄鄰居 i 是否小於中心像素亮度。本實作採用 9×7 window，共 63 bit 剛好放進 uint64。對應的 cost 即為左右 Census code 的 Hamming distance：

$$C(d, y, x) = \text{popcount}(\text{census}_L(y, x) \oplus \text{census}_R(y, x-d)). \quad (1)$$

為了在新舊 numpy 上都有好效率，採取雙策略：**numpy ≥ 2.0** 使用內建的 `np.bitwise_count` (SIMD popcount，最快)；舊版環境則 fallback 至 SWAR (SIMD-Within-A-Register) popcount，比 byte-wise lookup table 快約 3.5 $\times$ 。

進一步觀察到 Census 是**對稱**的 ($\text{Ham}(a, b) = \text{Ham}(b, a)$)，所以右圖 anchored 的 cost volume 可由左 anchored 的 cost volume 透過 $x' \mapsto x' + d$ 的 column reindex 取得，省下一整輪 Hamming pass (速度增益約 30%)。

2.3 Step 2: Cost Aggregation —Weighted Guided Image Filter

傳統的 Guided Filter [3] 在固定 ε 之下，邊緣保留度受限。本實作改用 Weighted Guided Image Filter (WGIF) [4] 的核心想法：每像素根據本地紋理 importance 自適應地調整 ε ：

$$\gamma(x) = \frac{\sigma_I^2(x) + \varepsilon_0}{\sigma_I^2 + \varepsilon_0}, \quad \varepsilon(x) = \frac{\varepsilon}{\gamma(x)}. \quad (2)$$

其中 $\sigma_I^2(x)$ 為 guide 影像在以 x 為中心的視窗變異數。 γ 在邊緣處 (高 variance) 較大、平滑區域較小，因此 $\varepsilon(x)$ 在邊緣處變小 (強保留)、平滑區域變大 (強平滑)。

對 TA invariance 規範的合規性。 本層 adaptation 完全由 **影像本身的 local feature** (variance) 驅動，與 `maxd`、`image name`、`runtime context` 無關，符合 2026-05-27 規範「不可硬編碼 per-image 分支」。

2.4 Step 3: Winner-Take-All

取 $D_L(y, x) = \text{argmin}_d C(d, y, x)$ 。為節省一輪 aggregation，右側 disparity D_R 直接以**未經 aggregation 的** reindex cost 做 WTA；經 sweep 比較，此設計在 4 對影像的 BPR 乘積上一致勝過「左右皆 aggregation」的版本，直觀解釋為 D_R 只用於後續 LRC 一致性遮罩、本身精確度的微小變化對最終遮罩影響很小，但省下的 aggregation 時間是實打實的。

2.5 Step 4: Refinement —LRC + Hole Fill + WMF

Left-right consistency check.

$$\text{valid}(y, x) \Leftrightarrow |D_L(y, x) - D_R(y, x - D_L(y, x))| \leq 1. \quad (3)$$

Hole filling. 對每列雙向 sweep 取「左邊最近有效值」與「右邊最近有效值」逐像素取較小者，並在影像邊緣初始化為 maxd （避免整列無效時 collapse 為 0）。

Weighted Median Filter. 以填補後的整數 disparity 為輸入、左圖為 guide，呼叫 `cv2.ximgproc.weightedMedianFilter` (TA 允許的原語) 做最後的細緻化。半徑 15，window 內以 guide 顏色為相似度權重，能有效消除細小 outlier 而保留邊緣。

2.6 實作細節

Per-disparity thread pool. Cost build 與 WGIF aggregation 兩個外層迴圈都對 d 平行化。`numpy` 與 `cv2.boxFilter` 兩者都會釋放 GIL，所以在多核機上接近線性加速，cap 在 8 個 worker（再多會被 memory bandwidth 卡住）。

記憶體配置。 Cost volume 全程以 `float32` 持有 shape $(D+1, H, W)$ 。對 Teddy (450×375 ， $\text{max_disp} = 64$) 約 40 MiB，單機 8 GB RAM 綽綽有餘。

合規性。 全程僅使用允許的 `cv2.ximgproc` 原語；未使用 `cv2.StereoBM/StereoSGBM`/任何深度學習模型。同一組 hyperparameter (Census window 9×7 、WGIF radius 5、 $\varepsilon = 5 \times 10^{-4}$ 、WMF radius 15) 套用四對影像，**沒有 per-image 分支**。

2.7 實驗結果

在本機 (Intel x86_64, 8 核) 上對四對標準影像的結果如表 1。所有影像皆滿足 TA 門檻。

Table 1: Middlebury v2 BPR (threshold = 1 px) —`computeDisp.py` v6。

影像	我們的 BPR	TA 門檻	是否通過	本機時間
Tsukuba	3.25 %	< 8 %	✓	0.20 s
Venus	0.34 %	< 5 %	✓	0.25 s
Teddy	10.00 %	< 18 %	✓	0.27 s
Cones	8.78 %	< 15 %	✓	0.27 s

Codalab 線上評分。 v5 baseline 為 **10.76** (Tsukuba 3.07 / Venus 0.36 / Teddy 10.22；time 0.97 s 內)。v6 引入 WGIF + adaptive ε 後最終分數為 **TODO (待補)**，預期可進一步降低 Teddy 的錯誤率。




Figure 2: 四對 Middlebury 影像的預測 disparity map。色階為視覺化用，輸出實際上為 uint8 整數 disparity。

3 加分題：TartanAir 3D 場景重建

3.1 任務動機與資料集選擇

加分題的核心目標是「在真實世界場景延伸立體匹配」，並提交**示範影片**。要做出有意義的 3D 場景重建需要**多視角融合** (multi-view fusion)，進而需要相機的**已知姿態** (pose) 作為座標基準。我們評估了三個候選資料集：

資料集	提供的資訊	採用與否
EuRoC MAV (V1)	立體 + IMU + GT pose	主機 TCP 連不到 ethz.ch；放棄
KITTI Raw	立體 + OXTS GPS/INS pose	缺密集 GT depth，無法 BPR 對照
TartanAir V1	立體 + GT depth + GT pose (合成)	採用

TartanAir [5] 雖為合成資料，但同時提供了 rectified 立體影像對、密集 GT depth (.npz float32 公尺)、以及每 frame 的 GT pose (tx ty tz qx qy qz qw 每列)，這讓我們能在同一場景中 **同時** 做 BPR 量化評估與 3D 重建視覺驗證。內參全資料集統一： $f_x = f_y = 320$, $c_x = 320$, $c_y = 240$ (即 640×480)，baseline $B = 0.25$ m。本報告使用 `japanesealley/Hard/P000` 軌跡的前 100 frame 作為 baseline。

3.2 Pipeline 架構

完整 pipeline 如 Figure 3。computeDisp 直接重用基礎題的 v6 實作 (API 完全相同)，保證加分題的工作無法影響到 80% 的基礎分。




Figure 3: Bonus pipeline。Pose 在進入 TSDF 之前已從 TartanAir 的 NED body axes 轉成 OpenCV camera axes (見 §3.3)。

3.3 關鍵技術點：NED → OpenCV 軸排列轉換

這是整個 bonus pipeline 跑起來的**關鍵步驟**，沒做這一步重建幾何會完全錯掉。

TartanAir 的 `pose_left.txt` 每列是相機在世界座標下的位姿，使用 **NED 機體座標系**（北東地， $x=\text{forward}$, $y=\text{right}$, $z=\text{down}$ ）。但 `depth_left.npy` 的反投影、Open3D 的 TSDF 整合、以及 OpenCV 的所有相機運算都假設 **OpenCV 相機座標系**（ $x=\text{right}$, $y=\text{down}$, $z=\text{forward}$ ）。兩者之間是固定軸排列：

$$\mathbf{M}_{\text{NED} \rightarrow \text{CV}} = \begin{pmatrix} 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}, \quad T_{wc}^{\text{CV}} = T_{wc}^{\text{NED}} \mathbf{M}_{\text{NED} \rightarrow \text{CV}}. \quad (4)$$

未做此轉換時，深度沿 OpenCV 的 $+z$ (forward) 反投影，但被一個 forward 軸是 $+x$ 的 pose 變換，所有重建點都會落在世界 z (垂直) 方向，造成的視覺效果是場景在相機高度上方 3–15 m 出現一片飄浮 mesh，而相機軌跡卻在 $z \approx 0.6$ m。

Sanity check. P000 frame 0 的左右相機 GT translation 差距 $\|\mathbf{t}_L - \mathbf{t}_R\| = 0.2500$ m，恰好等於資料集規格的 baseline，驗證 (i) translation 單位是公尺、(ii) 左右相機 rotation 一致。

3.4 TSDF Fusion 參數選擇

採用 Open3D 的 `ScalableTSDFVolume` (Curless–Levoy [6] 的 hierarchical 版本，與 KinectFusion [7] 同一族)：

- **voxel size** = 0.05 m。日式巷弄寬約 10–20 m，0.05 m 維持牆面細節而不爆 voxel 數。
- **SDF trunc** = $4 \times \text{voxel}$ (業界常用比例)。
- **Depth trunc** = 15 m。古典立體匹配的深度雜訊隨距離成 $Z^2/(f_x B)$ 增長，超過此距離的 sample 多半是 noise，留下只會把 mesh 拉花。
- **Sky 像素遮罩**：TartanAir 將天空/超範圍 depth 記為 ≈ 65504 (float16 max)；我們以 65000 為門檻將其歸零。Open3D 把 $\text{depth} = 0$ 視為無效並略過，但對「 $> \text{depth_trunc}$ 」會 clip 為 trunc 距離 $\rightarrow$ 在 15 m 處長出幻影牆面，所以這兩種 invalid 都要顯式歸零。

3.5 第一人稱走訪渲染

我們刻意選擇 **follow-trajectory** (沿原始軌跡) 而非 **orbit** (環繞) 渲染：

1. 不需要在世界座標中定義「up」軸，避開合成資料集 world frame 的 up 模糊問題。
2. 每個 frame 的 virtual camera 都放在原始拍攝姿態上，產生的影片可與原始 left image 像素級重疊；只要對到，就是重建品質的直接視覺證據。
3. 渲染畫布 1280×960 (原解析度 $2 \times \text{upscale}$)，保持 aspect ratio 不變，內參 K 同步放大以保證 FOV 一致。

3.6 BPR 對 GT depth 之診斷

雖然 bonus 評分以「示範影片」為主，我們仍對 `computeDisp` 在 TartanAir 上做量化評估：把 GT depth 換算為 GT disparity $d_{\text{gt}} = f_x B / Z$ ，再以 Middlebury 風格計算 BPR。Valid mask

排除：(a) sky/inf 像素 ($\text{depth} \geq 65000$)，(b) $d_{\text{gt}} > \text{maxd}$ 的像素（搜尋範圍外，算錯只是測量搜尋範圍）。Coverage 平均 98.8 %。

Table 2: japanesalley/Hard/P000, frame 0–99, $\text{max_disp} = 64$ ；同機 $\sim 0.36 \text{ s/frame}$.

Threshold	mean	median	worst	best
1.0 px	20.21 %	20.17 %	33.31 %	9.51 %
3.0 px	10.75 %	10.18 %	26.86 %	2.83 %

誠實的數字解讀。 古典立體匹配在 TartanAir 合成紋理上不可能達到 1 % BPR，與我們的數字相符（10–30 % 區間是該資料集上 classical stereo 的常見水準）。我們也試了 Easy levels 與 office/Easy（室內辦公室），1 px BPR 反而升到 40–46 %——原因是這些場景物體較近，需要更寬的 disparity 搜尋範圍，模糊性反而上升。P000 的遠距軌跡剛好是古典演算法擅長的條件。Figure 4 為單張 frame 的視覺對照。




Figure 4: frame 30 of japanesalley/Hard/P000：(a) 左圖、(b) v6 預測 disparity、(c) GT disparity、(d) $|\text{pred} - \text{gt}|$ (5 px clip)。錯誤集中在巷尾的遠距離、低紋理區域。

3.7 重建結果

Figure 5 呈現走訪影片在第 40 frame 的靜止截圖：v6 重建與 GT-depth 上限參考，兩者 mesh 的整體幾何(牆面、地面、近距離物件)對得起來。完整 mp4 在 out/tartanair_p000_v6_100.mp4

與 out/tartanair_p000_gt_100.mp4 (git commit d89c5bb 後產生)。



(a) v6 重建 (main 加分題交付物)



(b) GT depth 上限參考

Figure 5: First-person walkthrough frame 40 截圖。雖然 v6 BPR 仍有 $\sim 20\%$ ，經過 TSDF 多視角融合後表面在視覺上仍清晰可辨——這正是 multi-view fusion 的價值：每幀的隨機 noise 在累積平均下被有效削減。

3.8 與 v8 替代版本之比較

我們也試了同學提供的替代實作 `computeDisp_v8.py`，其與 v6 的主要差別是：(i) 多了 parabolic sub-pixel refinement、(ii) WMF 對 sub-pixel disparity 做。理論上這兩項在 disparity 精度上應該優於 v6 的純整數版本。但在 TartanAir 上的 BPR 結果：v8 在 1px 為 20.26%、3px 為 10.75%，與 v6 **基本打平**（差距在 ± 0.05 pp 內）。原因清楚：`computeDisp` 的 API 回傳 `uint8`，sub-pixel 的小數部分在這個 API 邊界被 clip 掉。此觀察對下游使用者重要：要享受 sub-pixel 改善，**下游必須消費 float disparity**（例如直接拿 cost volume 做 fusion，或將 disparity 改回 `float32` 接口）。

4 討論與結論

基礎題。 v6 在四對 Middlebury 影像上皆滿足 TA 門檻（最緊的 Cones $< 15\%$ 我們做到 8.78%），且使用單一組 hyperparameter，WGIF 的 per-pixel $\varepsilon(x)$ 完全由影像 variance 驅動，合於 2026-05-27 補充規範。

加分題。 我們交付的核心是**第一人稱走訪影片**，這直接對應 project doc 的“demonstration video showcasing dynamic results”要求；20.21% 的 BPR 是**誠實的量化報告**——古典 stereo 在合成紋理上本來就達不到 1%，重點在 multi-view TSDF fusion 將每幀的隨機 noise 抑制到視覺上可接受的水準。最關鍵的技術點是 NED $\rightarrow$ OpenCV pose 轉換（式 4），未做時 mesh 會飄在空中。

Limitations. (i) 合成紋理，移植到真實 KITTI 時 BPR 可能下降；(ii) 我們的 occlusion 處理止於 LRC，沒有 hole inpainting；(iii) Mesh 沒做 outlier filtering（如 confidence-weighted TSDF）。

Future Work. 更大尺度的 orbit overview render、引入 confidence 加權的 TSDF (reduce mesh noise)、以及把同學的 v8 sub-pixel 訊號直接送進 TSDF (修改 API 為 `float32`) 以驗證 sub-pixel 對 fusion 品質的潛在貢獻。

References

- [1] D. Scharstein and R. Szeliski. “A Taxonomy and Evaluation of Dense Two-Frame Stereo Correspondence Algorithms”. In: *International Journal of Computer Vision* 47.1–3 (2002), pp. 7–42.
- [2] R. Zabih and J. Woodfill. “Non-Parametric Local Transforms for Computing Visual Correspondence”. In: *European Conference on Computer Vision (ECCV)*. 1994, pp. 151–158.
- [3] K. He, J. Sun, and X. Tang. “Guided Image Filtering”. In: *European Conference on Computer Vision (ECCV)*. 2010, pp. 1–14.
- [4] Z. Li et al. “Weighted Guided Image Filtering”. In: *IEEE Transactions on Image Processing* 24.1 (2015), pp. 120–129.
- [5] W. Wang et al. “TartanAir: A Dataset to Push the Limits of Visual SLAM”. In: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. 2020, pp. 4909–4916.
- [6] B. Curless and M. Levoy. “A Volumetric Method for Building Complex Models from Range Images”. In: *SIGGRAPH*. 1996, pp. 303–312.
- [7] R. A. Newcombe et al. “KinectFusion: Real-Time Dense Surface Mapping and Tracking”. In: *IEEE International Symposium on Mixed and Augmented Reality (ISMAR)*. 2011, pp. 127–136.